

Computational Stats

Group III

Trabalho 1

Exercício 1

1. Considere que uma variável contínua X com a seguinte função de densidade:

$$f(x) = \begin{cases} \frac{4}{3}(x^3 + x) & 0 < x < 1 \\ 0, & \text{for all others } x \text{ values} \end{cases}$$

Agora considerando a variável aliatória $Y = g(X)$, em que $g(x) = \log(x^2 + 4)$. Estime o valor $P(1.3 < Y < 1.5)$ usando o método de monte carlo e estime o valor do desvio padrão da estimativa

$$P(1.3 < Y < 1.5) = P(1.3 < g(x) < 1.5)$$

$$D(g(x)) = D(\log(x^2 + 4)) = [\min(\log(x^2 + 4), +\infty[\quad , \quad \min(\log(x^2 + 4)) = \log(4) = 1.386294 > 1.3$$

Onde $D(g(x))$ é o domínio de $g(x)$. Uma vez que $D(g(x))$ está definido no intervalo $[\min(\log(x^2 + 4), +\infty[$ afirmar o seguinte:

$$P(1.3 < g(x) < \log(4)) = 0 \quad \implies \quad P(1.3 < g(x) < 1.5) \equiv P(\log(4) < g(X) < 1.5)$$

Que se pode desenvolver :

$$P(\log(4) < \log(x^2 + 4) < 1.5) = P(4 < x^2 + 4 < e^{1.5}) = P(0 < x^2 < e^{1.5} - 4) = P(0 < x < \sqrt{e^{1.5} - 4})$$

Agora, sabemos que a probabilidade que queremos calcular pode ser obtida através do seguinte integral:

$$\int_0^{\sqrt{e^{1.5}-4}} \frac{4}{3}(x^3 + x) dx$$

O qual poderá ser escrito com a seguinte mudança de variável:

Mudança de Variável

$$z(x) = xc \quad , \quad z(\sqrt{e^{1.5}-4}) = 1 \quad \implies \quad c = \frac{1}{\sqrt{e^{1.5}-4}}$$

$$x = z\sqrt{e^{1.5}-4} \quad \implies \quad x' = \sqrt{e^{1.5}-4}$$

No que resulta no seguinte integral:

$$\int_0^{\sqrt{e^{1.5}-4}} \frac{4}{3}(x^3 + x) dx \quad \equiv \quad \frac{4}{3} \int_0^1 ((z\sqrt{e^{1.5}-4})^3 + z\sqrt{e^{1.5}-4}) \cdot \sqrt{e^{1.5}-4} dz \equiv \frac{4}{3}(e^{1.5}-4) \int_0^1 (z^3(e^{1.5}-4) + z) \cdot 1 dx$$

Onde podemos usar o método de monte carlo para estimar

$$\int_0^1 (z^3(e^{1.5} - 1) + z) \cdot 1 \, dx$$

, assumindo que z segue uma distribuição $U(0, 1)$.

$$\int_0^1 (z^3(e^{1.5} - 4) + z) \cdot 1 \, dx \approx \hat{\theta} = \frac{\sum_{i=1}^n (z_i^3 \cdot (e^{1.5} - 4) + z_i)}{n}$$

Calculo do estimador $\hat{\theta}$ do valor esperado do integral anterior.

```
int_func <- function(z){
  res=(z^3)*(exp(1.5)-4)+z
}

#z follows an uniform

sample <- runif(1000)
int_est <- mean(int_func(sample))
prob_value <- (4/3)*(exp(1.5)-4)*int_est
```

Assim sendo:

$$P(1.3 < x < 1.5) = 0.3960328$$

Cálculo do desvio padrão do estimador da probabilidade

$$\text{var}(P(1.3 < Y < 1.5)) = \left(\frac{4}{3}(e^{1.5} - 4)\right)^2 \cdot \text{var}(\theta)$$

```
varEstimator <- (1/(length(sample)^2))*sum(((4/3)*(exp(1.5)-4)*int_func(sample)-prob_value)^2)
df <- data.frame(
  probEstimated = prob_value,
  stdMC = sqrt(varEstimator)
)

knitr::kable(df)
```

probEstimated	stdMC
0.3960328	0.0083966

Exercise 2

2.1

$$E(e^{x+y}) = E(e^x + e^y)$$

Sendo:

$$E(X) = \int_D x \cdot f(x) \, dx$$

, onde X é uma variável aleatória e f(x) a sua função densidade de probabilidade.

Temos:

$$\int_0^\infty \int_0^\infty e^{x+y} \cdot \frac{2}{\sqrt{2\pi}} \cdot e^{\frac{-x^2}{2}} \cdot \frac{2}{\sqrt{2\pi}} \cdot e^{\frac{-y^2}{2}} dx dy = \frac{2}{\pi} \int_0^\infty \int_0^\infty e^x \cdot e^{\frac{-x^2}{2}} \cdot e^y \cdot e^{\frac{-y^2}{2}} dx dy$$

Fazendo as seguintes mudanças de variável:

$$\alpha = e^{-x} \implies x = -\log(\alpha)$$

$$\beta = e^{-y} \implies y = -\log(\beta)$$

Ficamos com os seguintes limites de integração para α :

$$\lim_{x \rightarrow \infty} e^{-x} = 0$$

$$\lim_{x \rightarrow 0} e^{-x} = 1$$

e para β :

$$\lim_{y \rightarrow \infty} e^{-y} = 0$$

$$\lim_{y \rightarrow 0} e^{-y} = 1$$

Substituindo na equação, temos:

$$\begin{aligned} & \frac{2}{\pi} \int_1^0 \int_1^0 e^{-\log(\alpha)} \cdot e^{\frac{-(-\log^2(\alpha))}{2}} \cdot \left(-\frac{1}{\alpha}\right) \cdot e^{-\log(\beta)} \cdot e^{\frac{-(-\log^2(\beta))}{2}} \cdot \left(-\frac{1}{\beta}\right) d\alpha d\beta \\ &= \frac{2}{\pi} \cdot \left(-\int_0^1 e^{-\log(\alpha)} \cdot e^{\frac{-(-\log^2(\alpha))}{2}} \cdot \frac{1}{\alpha} d\alpha\right) \cdot \left(-\int_0^1 e^{-\log(\beta)} \cdot e^{\frac{-(-\log^2(\beta))}{2}} \cdot \frac{1}{\beta} d\beta\right) \\ &= \frac{2}{\pi} \cdot \int_0^1 e^{-\log(\alpha)} \cdot e^{\frac{-\log^2(\alpha)}{2}} \cdot \frac{1}{\alpha} d\alpha \int_0^1 e^{-\log(\beta)} \cdot e^{\frac{-\log^2(\beta)}{2}} \cdot \frac{1}{\beta} d\beta \\ &= \frac{2}{\pi} \cdot \int_0^1 e^{-\log(\alpha) \cdot (1 + \frac{1}{2}\log(\alpha))} \cdot \frac{1}{\alpha} d\alpha \cdot \int_0^1 e^{-\log(\beta) \cdot (1 + \frac{1}{2}\log(\beta))} \cdot \frac{1}{\beta} d\beta \\ &= \frac{2}{\pi} \cdot \int_0^1 e^{-\log(\alpha) \cdot (1 + \frac{1}{2}\log(\alpha))} \cdot \frac{1}{\alpha} \cdot 1 d\alpha \cdot \int_0^1 e^{-\log(\beta) \cdot (1 + \frac{1}{2}\log(\beta))} \cdot \frac{1}{\beta} \cdot 1 d\beta \\ &= \frac{2}{\pi} \cdot \int_0^1 e^{-\log(\alpha) \cdot (1 + \frac{1}{2}\log(\alpha))} \cdot \frac{1}{\alpha} \cdot \frac{1}{1-0} d\alpha \cdot \int_0^1 e^{-\log(\beta) \cdot (1 + \frac{1}{2}\log(\beta))} \cdot \frac{1}{\beta} \cdot \frac{1}{1-0} d\beta \end{aligned}$$

Sendo:

$$h_1(\alpha) = e^{-\log(\alpha) \cdot (1 + \frac{1}{2}\log(\alpha))} \cdot \frac{1}{\alpha} \cdot \frac{1}{1-0}$$

$$g_1(\alpha) = e^{-\log(\alpha) \cdot (1 + \frac{1}{2}\log(\alpha))} \cdot \frac{1}{\alpha}$$

$$f_1(\alpha) = \frac{1}{1-0}$$

$$h_2(\beta) = e^{-\log(\beta) \cdot (1 + \frac{1}{2} \log(\beta))} \cdot \frac{1}{\beta} \cdot \frac{1}{1-0}.$$

$$g_2(\beta) = e^{-\log(\beta) \cdot (1 + \frac{1}{2} \log(\beta))} \cdot \frac{1}{\beta}$$

$$f_2(\beta) = \frac{1}{1-0}$$

Onde:

$$f_1(\alpha), f_2(\beta) \sim \mathcal{U}(1, 0)$$

e,

$$f_1(\alpha), f_2(\beta) \geq 0$$

Estamos em condições de aplicar Monte Carlo:

$$\begin{cases} \theta_1 = \int_D h_1(\alpha) d\alpha = \int_D g_1(\alpha) \cdot f_1(\alpha) d\alpha = E(g_1(X)) \\ \theta_2 = \int_D h_2(\beta) d\beta = \int_D g_2(\beta) \cdot f_2(\beta) d\beta = E(g_2(Y)) \end{cases}$$

Se tivermos uma amostra aleatória x_1, \dots, x_n da variável aleatória X com densidade f , um estimador θ é:

$$\begin{cases} \hat{\theta}_1 = \sum_{i=1}^n \frac{g_1(x_i)}{n} \\ \hat{\theta}_2 = \sum_{i=1}^n \frac{g_2(y_i)}{n} \end{cases}$$

Finalmente:

$$E(e^{\hat{x}+y}) = \hat{\theta} = \frac{2}{\pi} \cdot \hat{\theta}_1 \cdot \hat{\theta}_2$$

A variância de $\hat{\theta}$ será:

$$v = Var(\frac{2}{\pi} \cdot \hat{\theta}_1 \cdot \hat{\theta}_2) = \frac{4}{\pi^2} \cdot Var(\hat{\theta}_1) \cdot Var(\hat{\theta}_2)$$

Aplicando o método de Monte Carlo, ficamos com:

$$\begin{cases} \hat{Var}(\hat{\theta}_1) = \frac{1}{n^2} \sum_{i=1}^n (g_1(x_i) - \hat{\theta}_1)^2 \\ \hat{Var}(\hat{\theta}_2) = \frac{1}{n^2} \sum_{i=1}^n (g_2(y_i) - \hat{\theta}_2)^2 \end{cases}$$

Substituindo na equação inicial:

$$\hat{v} = \frac{4}{\pi^2} \cdot \sum_{i=1}^n \frac{(g_1(x_i) - \theta)^2}{n} \cdot \sum_{i=1}^n \frac{(g_2(y_i) - \theta)^2}{n}$$

Implementação do método:

Determinação do estimador e do estimador da variancia

```
set.seed(1)
n<-1000
u1<-runif(n)
u2<-runif(n)
g1<-function(x){exp(-log(x)*(1+(1/2)*log(x)))*(1/x)}
g2<-function(y){exp(-log(y)*(1+(1/2)*log(y)))*(1/y)}
teta<-(2/pi)*mean(g1(u1))*mean(g2(u2))
teta1<-mean(g1(u1))
teta2<-mean(g2(u2))

v<-(4/(pi^2))*(mean((g1(u1)-teta1)^2)/n)*(mean((g2(u2)-teta2)^2)/n)
df <- data.frame(
  probEstimated = teta,
  varianceMC = v
)

knitr::kable(df)
```

probEstimated	varianceMC
7.874321	8.3e-06

2.2

Dado que:

X, Y random variables with p.d.f.:

$$f(x) = \frac{2}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, 0 < x < +\infty$$

precisamos de estimar o parâmetro θ com o Método de Monte Carlo utilizando uma variável que não seja Uniforme, onde o parâmetro θ é definido como:

$$\theta = E(e^{X+Y})$$

Trabalhar o estimador

$$\theta = E(e^{X+Y}) = E(e^X \times e^Y) = E(e^X) \times E(e^Y)$$

$$= \int_0^{+\infty} e^x \frac{2}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \times \int_0^{+\infty} e^y \frac{2}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy$$

Este integral não atende às condições para o Método de Monte Carlo ser aplicado, e portanto é necessário trabalhar o integral de maneira a que seja possível aplicar o método.

Mudança de variável

Ao aplicar a seguinte mudança de variável:

$$x = \varphi(t) = \sqrt{t}$$

$$t = \varphi^{-1}(x) = x^2$$

$$\varphi'(t) = (\sqrt{t})' = (t^{\frac{1}{2}})' = \frac{1}{2}t^{-\frac{1}{2}}$$

$$\lim_{t \rightarrow +\infty} \sqrt{t} = +\infty$$

$$\lim_{t \rightarrow 0} \sqrt{t} = 0$$

podemos reorganizar o integral da seguinte maneira:

$$x = \varphi(t) = t_x, y = \varphi(t) = t_y$$

$$\int_0^{+\infty} e^{\sqrt{t_x}} \frac{2}{\sqrt{2\pi}} e^{-\frac{1}{2}t_x} \frac{1}{2} t_x^{-\frac{1}{2}} dt_x \times \int_0^{+\infty} e^{\sqrt{t_y}} \frac{2}{\sqrt{2\pi}} e^{-\frac{1}{2}t_y} \frac{1}{2} t_y^{-\frac{1}{2}} dt_y$$

Re-ordenando a equação, estamos agora em condições de aplicar o Método de Monte Carlo uma vez que o integral é definido pela multiplicação de:

1. uma p.d.f. $f(x)$ conhecida
2. uma outra função $g(x)$

$$\int_0^{+\infty} e^{\sqrt{t_x}} \frac{2}{\sqrt{2\pi}} t_x^{-\frac{1}{2}} \frac{1}{2} e^{-\frac{1}{2}t_x} dt_x \times \int_0^{+\infty} e^{\sqrt{t_y}} \frac{2}{\sqrt{2\pi}} t_y^{-\frac{1}{2}} \frac{1}{2} e^{-\frac{1}{2}t_y} dt_y$$

onde:

$$g(x) = e^{\sqrt{x}} \frac{2}{\sqrt{2\pi}} x^{-\frac{1}{2}} \quad \text{and} \quad f(x) = \frac{1}{2} e^{-\frac{1}{2}x}$$

onde $f(x)$ é a função distribuição densidade de uma variável Exponencial com $\lambda = \frac{1}{2}$:

$$X \sim \text{Exp}\left(\frac{1}{2}\right)$$

Portanto, é agora necessário gerar amostras aleatórias de $X \sim \text{Exp}(\frac{1}{2})$

Gerar uma variável com distribuição Exponencial utilizando o Método da Transformação Inversa

Começemos com a função distribuição cumulativa de uma variável Exponencial, que é definida por:

$$F(X) = 1 - e^{-\lambda x}, \quad x \in \mathbb{R}$$

Tendo em consideração que o resultado de $F(X)$ é um número real entre 0 e 1, e que:

1. $F(X)$ é uma função monótona não decrescente
2. $F(X)$ é uma função contínua

é sabido que $F(X)$ é invertível.

Implementação do método


```
set.seed(1)
lambda <- 0.5
N <- 1000
samples <- runif(N)

inverseExp <- function(u, lambda){
  -(1/lambda)*log(1-u)
}

values <- inverseExp(samples, lambda)

hist(values, breaks=100, freq = F)
lines(density(rexp(1000,0.5)))
```

Histogram of values



```

g <- function(x){
  exp(sqrt(x))*(2/(sqrt(2*pi)))*x^(-1/2)
}

X <- runif(N)
Y <- runif(N)

EX <- mean(g(inverseExp(X, lambda)))
EY <- mean(g(inverseExp(Y, lambda)))

theta2 <- EX*EY

vEX <- (1/(N^2))*sum((g(inverseExp(X, lambda))-EX)^2)
vEY <- (1/(N^2))*sum((g(inverseExp(Y, lambda))-EY)^2)

vtheta <-vEX*vEY

df <- data.frame(
  probEstimated = theta2,
  varianceMC = vtheta
)

knitr::kable(df)

```

probEstimated	varianceMC
7.901322	2.4e-06

2.3

$$\hat{\theta} = E(e^{x+y}) \quad var(\hat{\theta}) = \frac{4}{\pi^2} \cdot \sum_{i=1}^n \frac{(g_1(x_i) - \hat{\theta})^2}{n} \cdot \sum_{i=1}^n \frac{(g_2(y_i) - \hat{\theta})^2}{n}$$

novo estimador:

$$\hat{\theta}_c = \hat{\theta} - \beta \cdot (c - \mu)$$

$$E(C) = \mu \quad var(\hat{\theta}_c) = var(\hat{\theta}) + \beta^2 \cdot var(C) - 2\beta cov(\hat{\theta}, C)$$

Queremos minimizar a variância, minimizando a variável β : para tal derivamos $var(\hat{\theta}_c)$ em ordem a β o que resulta na expressão: $var(\hat{\theta}_c)' = 2\beta var(C) - 2cov(\hat{\theta}, C)$

Com $var(\hat{\theta}_c)' = 0$ iremos obter os extremos. $\beta = \frac{-2cov(\hat{\theta}, C)}{2var(C)}$

Calculo auxiliares:

$$b) \quad var(\hat{\theta}) = Var\left(\frac{2}{\pi} \cdot (\hat{\theta}_1, \hat{\theta}_2)\right) = \frac{4}{\pi^2} \cdot Var(\hat{\theta}_1) \cdot Var(\hat{\theta}_2)$$

$$E(C) = E\left(\frac{1}{n} \cdot \sum_{i=0}^n u_i v_i\right) = \frac{1}{n} \sum (E(u) \cdot E(v)) = E(u) \cdot E(v) = \int_0^1 u \, du \cdot \int_0^1 v \, dv$$

$$var(C) = \frac{1}{n} \cdot \left(\int_0^1 f_c(x)^2 - E(C)^2 \right)$$

$$\begin{aligned}
Cov(\hat{\theta}, C) &= cov\left(\frac{1}{n} \sum_{i=1}^n g(U_i, V_i), \frac{1}{n} \sum_{i=1}^n U_i V_i\right) = \\
&= \frac{1}{n^2} \sum_{i=1}^n cov(g(U_i, V_i), U_i V_i) - \sum_{i=1}^n \sum_{j=1}^n cov(g(U_i, V_i), U_j V_j) =
\end{aligned}$$

Como os índices $i \neq j$ então $g(U_i, V_i)$ será independente de $U_j V_j$ e a sua covariância será Zero.

$$\begin{aligned}
&= \frac{1}{n^2} \sum_{i=1}^n cov(g(U_i, V_i), U_i V_i) - 0 = \\
&= \frac{1}{n} (E(g(U, V)UV)) - \frac{\theta}{4n}
\end{aligned}$$

$$E(g(U, V)UV) = \int_0^1 \int_0^1 uv.g(u, v) du dv$$

que será estimado em r pelo método de monte carlo

```

kk=1
res_final <- data.frame(integer(), double(), double(), double(), double())
n <- 10

while(kk<6) {
  if(kk!=1) {
    if(kk%%2!=0)
      n<-n*2
    else
      n<-n*5
  }
  set.seed(1)
  u1<-runif(n)
  u2<-runif(n)
  g1<-function(x){exp(-log(x)*(1+(1/2)*log(x)))*(1/x)}
  g2<-function(y){exp(-log(y)*(1+(1/2)*log(y)))*(1/y)}
  teta1<-mean(g1(u1))
  teta2<-mean(g2(u2))
  teta<-(2/pi)*mean(g1(u1))*mean(g2(u2))
  teta_var<-(4/(pi^2))*((mean((g1(u1)-teta1)^2))/n)*((mean((g2(u2)-teta2)^2))/n)
  df <- data.frame(
    probEstimated = teta,
    varianceMC = teta_var
  )

  g1_b<-function(x){exp(-log(x)*(1+(1/2)*log(x)))}
  g2_b<-function(y){exp(-log(y)*(1+(1/2)*log(y)))}
  covar_tc<-((1/n^2)*mean(g1_b(u1)*g2_b(u2)*u1*u2))-teta/(4*n^2)

  c_var<-(7/(n*144))
  beta<-covar_tc/(c_var)
  tetac<-(teta - (beta*((1/4) - mean(u1*u2))))
  tetac_var<-(teta_var+(beta^2)*c_var-2*beta*covar_tc)

  res<-data.frame(n, teta, teta_var, tetac, tetac_var)

```

```

    res_final<-rbind(res_final,res)
    kk<-kk+1
  }
knitr::kable(res_final)

```

n	teta	teta__var	tetac	tetac__var
10	7.114578	0.0728507	6.962646	0.0401382
50	7.444414	0.0024827	7.432106	0.0021721
100	7.604431	0.0006777	7.598763	0.0006353
500	7.839631	0.0000307	7.839400	0.0000303
1000	7.874321	0.0000083	7.874559	0.0000083